# 레퍼런스 기반 AI 보컬 믹싱 & 마스터링 시스템

레퍼런스 가이드 역전파를 통한 자율 음향 최적화

발표자: 이현중

2026.09

## 전체 목차 (Overview)


1. 믹스의 정의 및 전체 시스템 아키텍처
2. 핵심 도구 3종의 수학적 모델링 & 플러그인 설계
3. 최적화 메커니즘 (Optimization Mechanism)
4. 풀믹스 합산 (Summing with Instrumental)
5. 마스터링 체인 (Mastering Chain)
6. 결론 (Conclusion)

# 목차 (Table of Contents)


1 믹스의 정의 & 시스템 개요

2 핵심 도구 3종의 수학적 모델링 & 플러그인 설계

3 최적화 메커니즘 (Optimization Mechanism)

4 풀믹스 합산 (Summing with Instrumental)

5 마스터링 체인 (Mastering Chain)

6 결론 (Conclusion)

## 1. 믹스(Mixing)란 무엇인가?

- **정의**: 녹음된 개별 트랙들(보컬, 드럼, 베이스, 신스 등)을 음향학적·음악적으로 조율하여 단 하나의 트랙으로 결합하는 엔지니어링 과정.
- **믹싱의 3대 차원 (3D Audio Space)**:
  i. **주파수 차원 (Frequency / Height)**: 각 악기가 담당하는 주파수 영역을 분할하여 마스킹(소리 묻힘) 방지(ex. 저역이 풍부한 반주와 보컬).
  ii. **다이내믹스 차원 (Dynamics / Depth)**: 소리의 크고 작음의 폭을 제어하여 전후 거리감과 에너지 균일성 확보(ex. 하이라이트에서만 큰 보컬을 반주 속에 어떻게 넣느냐).
  iii. **시간·공간 차원 (Time & Space / Width & Reverb)**: 잔향을 통해 가상의 입체 음향 공간 구축.

> **보컬 믹싱의 궁극적 목표**: 보컬이 반주(MR)에 묻히지 않고 명료하게 들리면서도, 하나의 공간 안에서 일체감 있게 어우러지도록 만드는 것.

## 2. 실제 믹싱 현장에서는 어떤 작업을 하는가?

실제 스튜디오에서 엔지니어가 보컬 트랙을 처리하는 4단계 핵심 워크플로우:

1. **톤 쉐이핑 (Tone Shaping - EQ사용)**:
   - 보컬을 분석하여 특정 주파수대역을 깎거나(Cut) 부스트(Boost)하여 목표 주파수 밸런스 형성.
2. **다이내믹스 제어 (Dynamic Control - Compressor 사용)**:
   - 작은 소리부터 큰 샤우팅까지의 음량 편차를 줄여, 반주 위에서 일정한 에너지를 유지하도록 압축.
3. **공간감 형성 (Spatialization - Reverb 사용)**:
   - 무향실(흡음 부스)에서 건조하게 녹음된 보컬에 잔향(Tail)을 부여.
4. **레벨 밸런싱 & 서밍 (Level Balancing & Summing)**:
   - 보컬과 반주의 음량을 정밀하게 정렬하여 합산(Mixdown).

## 3. 기존 연구의 한계 vs 본 연구의 결정적 차이점

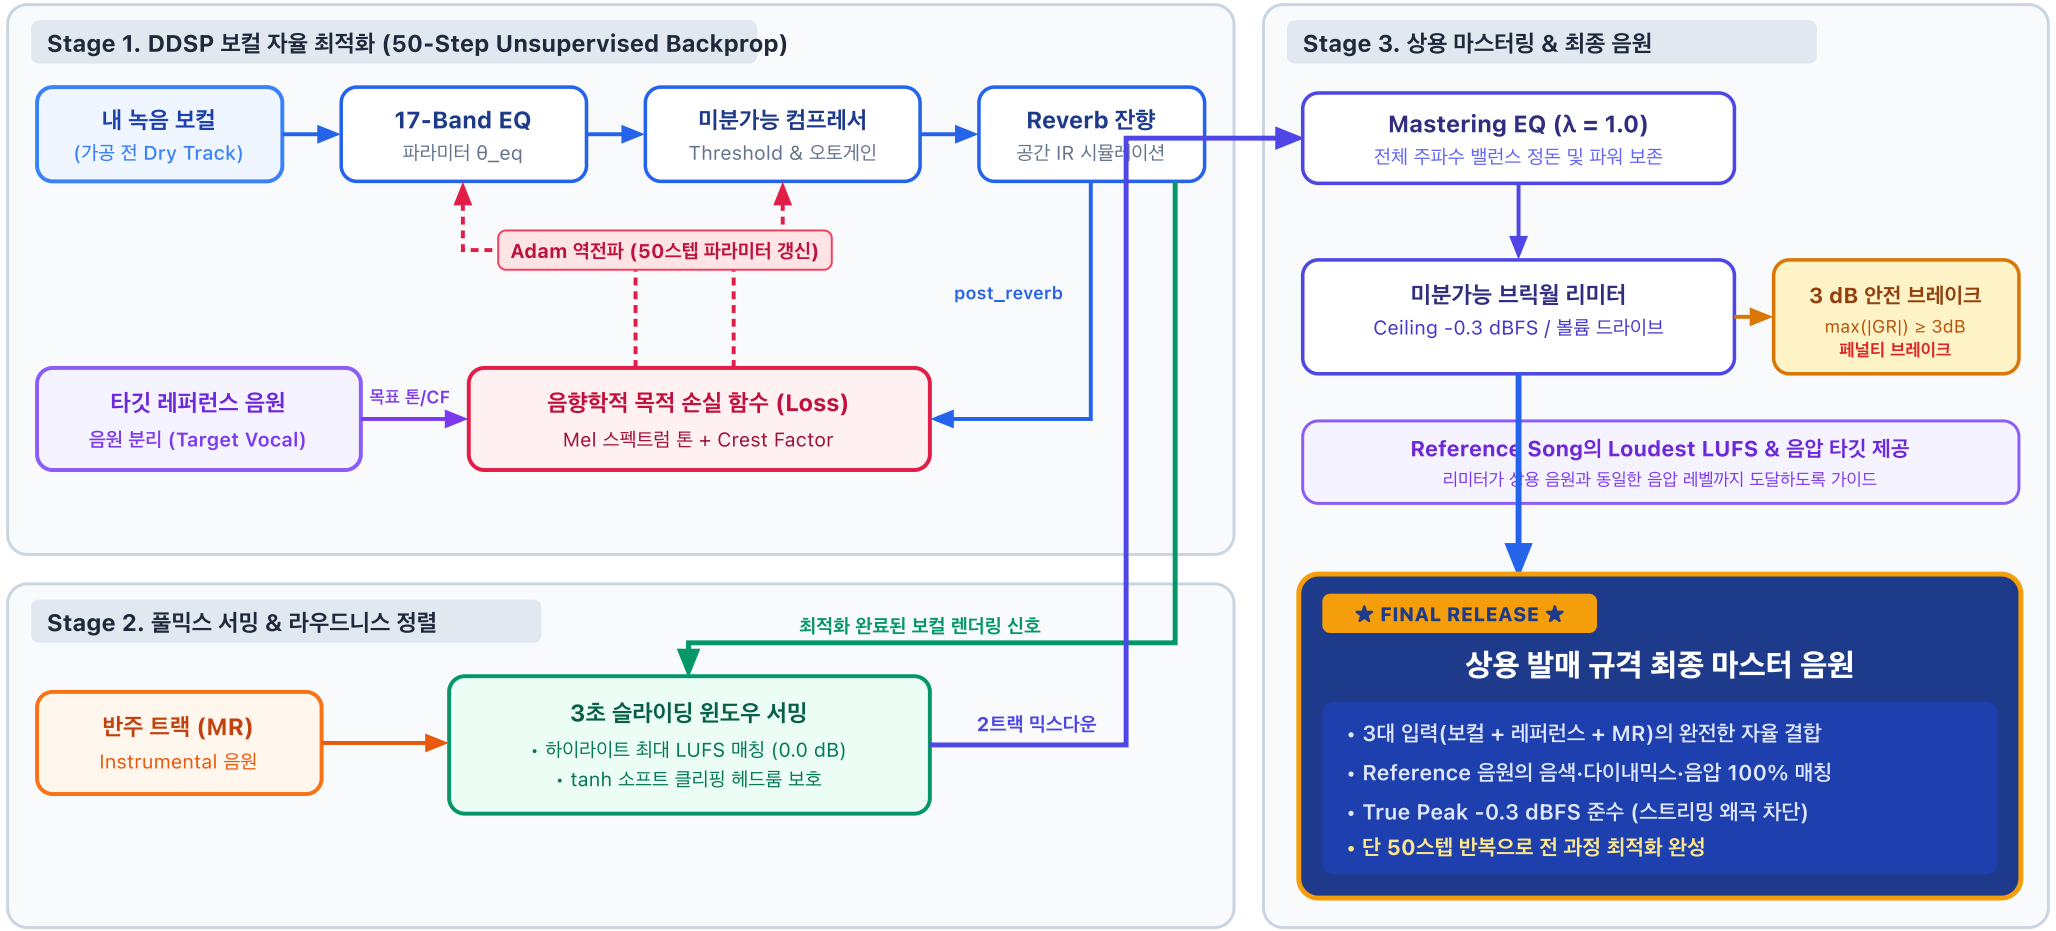
### ⚠️ 기존 믹싱 연구의 한계:

- **드라이(Dry) 신호의 부재**: 상용 발매곡에서 가공 전 순수한 원본 보컬을 구하는 것은 불가능함.
- **환경과 재료의 불일치**: 설령 프로 엔지니어의 설정값을 알아낸다 해도, **"그 수치가 내 보컬에도 잘 어울릴까?"**라는 근본적 한계 존재.
- 🍳 **요리에 비유하자면**:
  - 아무리 유명 셰프의 정밀한 레시피가 있어도, **내 주방 환경과 내가 가진 식재료의 상태가 다르면 다른 요리가 됨**이 됨.
  - 즉, 남의 프리셋이나 정답 데이터셋을 단순 복제하는 방식은 실제 환경에서 작동하지 않음.

### 💡 본 연구의 접근: Reference-Guided Unsupervised Optimization

- **완성된 맛을 나침반 삼아 자율 조율**: 레시피(파라미터)를 맹목적으로 베끼는 대신, 닮아가고 싶은 **완성된 요리(레퍼런스 음원)의 풍미(음색·다이내믹스 포락선)**를 목표로 설정.
- **내 재료 맞춤형 역전파**: 대규모 정답 데이터셋 없이, 미분 가능한 DSP(DDSP)를 통해 **내 보컬의 특성에 꼭 맞는 최적의 믹싱값을 직접 최적화**.

# 4. 전체 시스템 아키텍처 및 데이터 흐름도



# 목차 (Table of Contents)


1 믹스의 정의 & 시스템 개요

**2 핵심 도구 3종의 수학적 모델링 & 플러그인 설계**

3 최적화 메커니즘 (Optimization Mechanism)

4 풀믹스 합산 (Summing with Instrumental)

5 마스터링 체인 (Mastering Chain)

6 결론 (Conclusion)

## 5. 핵심 도구 3종의 역할과 공학적 목적

| 플러그인 | 음향학적 역할 | 공학적 목적 (최적화 목표) |
|---|---|---|
| 이퀄라이저 (Equalizer, EQ) | 주파수 응답($H(f)$) 보정 | 레퍼런스 보컬의 **스펙트럼 포락선(Mel Spectral Envelope)**과 내 보컬의 스펙트럼 거리 최소화 |
| 컴프레서 (Compressor) | 신호의 다이나믹레인지 감소 | 큰 신호를 눌러 **다이내믹 레인지(Crest Factor)**를 레퍼런스와 일치시킴 |
| 리버브 (Reverb) | 실내 음향 임펄스 응답(RIR) 잔향 부여 | 반주 공간에 맞는 잔향을 생성하여 입체감 형성 |

## 6. 미분 가능 EQ 설계: 17-Band Constant-Q 필터뱅크

주파수 축을 인간 청각 특성(바크/멜 스케일)에 맞추어 **옥타브 단위 등간격(Constant-Q)**으로 분할:

- 중심 주파수 배치 ($J = 17$, 범위 $200\ \text{Hz} \sim 10\ \text{kHz}$):

$$f_j = 200 \cdot 50^{\frac{j}{J-1}} \quad (j = 0, 1, \ldots, 16)$$

- 로그 주파수 간격 $\Delta$ 및 대역폭 $\sigma$:

$$c_j = \log_2 f_j, \qquad \Delta = \frac{\log_2 50}{16} \approx 0.3527\ \text{oct}, \qquad \sigma = 0.6\Delta \approx 0.2116\ \text{oct}$$

- 가우시안 필터뱅크 행렬 $\Phi \in \mathbb{R}^{F \times J}$ ($F = 1025$ STFT bins):

$$\Phi(f, j) = \exp\left(-\frac{(\log_2 f - c_j)^2}{2\sigma^2}\right)$$

- 전체 EQ 게인 커브 ($G_{\text{scale}} = 15\ \text{dB}$, 학습 파라미터 $\theta_{\text{eq}} \in \mathbb{R}^{17}$):

$$G_{\text{dB}}(f) = \sum_{j=0}^{J-1} \Phi(f, j) \cdot (G_{\text{scale}} \cdot \theta_j)$$

## 7. 왜 200 Hz - 10 kHz 대역만 제어하는가?

수학적 손실 함수가 음향 신호의 "물리적 결함"을 잘못 학습하는 현상을 방지하기 위한 핵심 필터링:

1. **하한선 200 Hz 제외 이유 (음원 분리 마스킹 손실)**:
   - 상용 레퍼런스 곡에서 보컬을 분리(Source Separation)할 때, $100 \sim 150\ \mathrm{Hz}$ 대역은 베이스/킥드럼에 심하게 마스킹되어 **보컬 정보 자체가 소실**됨.
   - 정보가 유실된 저역을 타깃으로 잡으면 EQ가 저역을 비정상적으로 왜곡 컷/부스트함.
2. **상한선 10 kHz 제외 이유 (코덱 절벽 현상)**:
   - 손실 압축 음원(MP3/AAC)은 고역($> 15\ \mathrm{kHz}$)을 강제로 잘라내는 **코덱 컷오프**를 지님.
   - 실제 측정 시 17 kHz 부근에서 $\mathrm{raw} - \mathrm{ref}$ 오차가 **$+50\ \mathrm{dB}$**까지 치솟음.
   - 이를 학습하면 EQ가 초고역을 극단적으로 깎아버려 보컬의 공기감(Air)이 파괴됨.

> **설계 원칙**: 평가 대역 $\Omega$와 제어 대역을 $[200, 10000]\ \mathrm{Hz}$로 일치시켜 **신뢰할 수 있는 구간에서만 수학적 최적화** 수행.

## 8. EQ의 위상 보존 및 에너지 보존 메이크업

### 1) 위상 보존 주파수 영역 곱셈

EQ 처리는 STFT 영역에서 위상(Phase)을 보존한 채 진폭에만 실수 게인을 곱함:

$$\mathcal{G}(f) = 10^{\alpha \cdot G_{\text{dB}}(f) \cdot M_{\text{eq}}(f)/20}, \qquad S'(f,t) = \mathcal{G}(f) \cdot S(f,t)$$

- 위상 왜곡(Phase Distortion)이 없어 빗살 필터(Comb Filtering) 현상이 원천 차단됨.

### 2) 에너지 보존 정규화 (Energy Conservation)

EQ로 특정 대역을 부스트하면 보컬 전체 볼륨이 커져 컴프레서의 동작점이 틀어짐:

$$g_{\text{norm}} = \sqrt{\frac{\sum_{f,t} |S(f,t)|^2}{\sum_{f,t} |S'(f,t)|^2 + \epsilon}}, \qquad y_{\text{eq}} = \text{iSTFT}(g_{\text{norm}} \cdot S')$$

- **효과**: 순수한 "톤(Tone)" 변화만 남기고 전체 음향 파워를 $1.0$으로 일정하게 보존.

## 9. 미분 가능 컴프레서: 피크 검출기와 전달함수

시간 영역에서 동작하며 autograd 역전파가 가능한 컴프레서 모델:

- 1단계: 블록 피크 검출기 ($H_d = 128$, $W_d = 256$, 2.9 ms 간격)

$$e_k = \max_{i \in [kH_d,\, kH_d + W_d)} |u[i]|, \qquad E_k = 20 \log_{10}(e_k + \epsilon)$$

- 2단계: 1차 IIR 평활화 (Attack $\tau_a = 0.5$ ms, Release $\tau_r = 120$ ms)

$$\alpha_a = \exp\left(-\frac{H_d}{f_s \tau_a}\right), \quad \alpha_r = \exp\left(-\frac{H_d}{f_s \tau_r}\right)$$

$$\bar{E}_k = \begin{cases} \alpha_a \bar{E}_{k-1} + (1 - \alpha_a) E_k & (E_k > \bar{E}_{k-1}) \\ \alpha_r \bar{E}_{k-1} + (1 - \alpha_r) E_k & (E_k \le \bar{E}_{k-1}) \end{cases}$$

- 3단계: 미분 가능한 Soft-Knee 전달함수 ($K = 4$ dB, 고정 Ratio $R = 10:1$)

$$F(y_k) = \begin{cases} y_k & (y_k \le T - K/2) \\ y_k + \left(\frac{1}{R} - 1\right) \frac{(y_k - T + K/2)^2}{2K} & (|y_k - T| \le K/2) \\ T + \frac{y_k - T}{R} & (y_k > T + K/2) \end{cases}$$

- 4단계: 오토 메이크업 게인(Auto Makeup) 및 최종 출력 파형 계산 ( `modules.py:392-408` )

$$\mathrm{GR}_k = F(\bar{E}_k) - \bar{E}_k \le 0 \text{ dB}, \qquad \overline{\mathrm{GR}}_{\text{active}} = \frac{1}{|M_{\text{active}}|} \sum_{k \in M_{\text{active}}} \mathrm{GR}_k$$

$$\text{net_gain}_k = \mathrm{GR}_k - \overline{\mathrm{GR}}_{\text{active}}, \qquad g_k = 10^{\text{net_gain}_k/20}$$

$$\tilde{g}[n] = \mathrm{Interp}(g_k), \qquad y_{\text{comp}}[n] = u[n] \cdot \tilde{g}[n]$$

  - EQ의 에너지 보존($g_{\text{norm}}$)처럼, 활성 발성 구간($M_{\text{active}}$)의 평균 감쇄량을 즉시 복원하여 사용 가능한 레벨을 유지 (역전파 손실이 아닌 DSP 순전파 물리 복원).

## 10. 미분 가능 리버브

실내 음향 잔향(Reverberation)을 물리적으로 모사하고 시간 영역에서 미분 가능한 리버브 모델:

- 1단계: 공간 지수 감쇄 포락선 (Decay Envelope, $\mathrm{RT}_{60}$)
  - 잔향 시간 $\mathrm{RT}_{60}$(에너지가 $-60\ \mathrm{dB}$ 감쇄하는 시간)에 따른 감쇄율 $\alpha$:

$$\alpha = \frac{3\ln 10}{\mathrm{RT}_{60} \cdot f_s} \approx \frac{6.9078}{\mathrm{RT}_{60} \cdot f_s}, \qquad e(t) = \exp(-\alpha t) \quad (0 \le t < T_{\mathrm{dur}})$$

- 2단계: 합성 RIR(Room Impulse Response) 생성 및 에너지 정규화
  - 독립된 좌/우 가우시안 백색 잡음($w_L, w_R$)에 감쇄 포락선을 곱해 스테레오 반사음 합성:

$$\mathrm{RIR}_L[t] = w_L[t] \cdot e(t), \qquad \mathrm{RIR}_R[t] = w_R[t] \cdot e(t)$$

$$\widetilde{\mathrm{RIR}}_c = \frac{\mathrm{RIR}_c}{\|\mathrm{RIR}_c\|_2 + \epsilon} \quad (c \in \{L, R\}) \quad \rightarrow \quad \text{잔향 부가로 인한 원치 않는 볼륨 증가 방지}$$

- **3단계: 주파수 영역 고속 FFT 컨볼루션 (Fast Convolution)**
  - 시간 영역 직접 연산 대신 주파수 영역 곱셈을 수행하여 실시간 처리 속도 확보:

$$y_{\text{wet},c} = \text{iFFT}\Big(\text{FFT}(x_{\text{pad}}) \cdot \text{FFT}(\widetilde{\text{RIR}}_c)\Big)$$

- **4단계: Dry / Wet 선형 믹싱 (최종 스테레오 출력)**
  - 원음(Dry)과 잔향(Wet)을 지정된 비율($\text{wet} \in [0, 1]$)로 합산:

$$y_{\text{rev},c}[n] = (1 - \text{wet}) \cdot x_{\text{pad}}[n] + \text{wet} \cdot y_{\text{wet},c}[n]$$

# 목차 (Table of Contents)


1 믹스의 정의 & 시스템 개요

2 핵심 도구 3종의 수학적 모델링 & 플러그인 설계

**3 최적화 메커니즘 (Optimization Mechanism)**

4 풀믹스 합산 (Summing with Instrumental)

5 마스터링 체인 (Mastering Chain)

6 결론 (Conclusion)

## 11. 톤(Tone) 최적화: Mel-Spectrogram 스펙트럼 손실 & 정규화

EQ 파라미터($\theta_{\text{eq}} \in \mathbb{R}^{17}$)를 조율하여 내 보컬의 음색을 레퍼런스 보컬과 일치시키는 최적화 기준:

### 1) Mel-Spectrogram 스펙트럼 톤 손실 ($\mathcal{L}_{\text{mel}}$)

멜 스케일로 유효 대역($\Omega = [200\ \text{Hz}, 10\ \text{kHz}]$) 내의 로그 스펙트럼 오차 산출:

$$\mathcal{L}_{\text{mel}} = \frac{1}{|\Omega|} \sum_{m \in \Omega} \left| \log_{10}(\Psi P_{\text{out}} + \epsilon)_m - \log_{10}(\Psi P_{\text{ref}} + \epsilon)_m \right|$$

- $\Psi \in \mathbb{R}^{M \times F}$: 선형 주파수를 80개 멜 밴드로 매핑하는 Mel 필터뱅크 행렬.
- $P_{\text{out}}, P_{\text{ref}}$: 출력 보컬 및 레퍼런스 보컬의 파워 스펙트럼.

### 2) 음향학적 정규화 손실 (과도 왜곡 및 빗살 필터 방지)

수학적 손실만 추종하다가 특정 주파수가 뾰족하게 치솟는 "기계적 위화감"을 억제하기 위한 2중 물리 제약:

$$\mathcal{L}_{\text{reg}} = \lambda_2 \|\theta_{\text{eq}}\|_2^2 + \lambda_s \|\Delta\theta_{\text{eq}}\|_2^2 \qquad (\lambda_2 = 0.1,\ \lambda_s = 0.1)$$

- **과도 부스트 억제 ($\ell_2$)**: $\|\theta_{\text{eq}}\|_2^2 = \sum_{j=0}^{16} \theta_j^2$ $\rightarrow$ 불필요하게 극단적인 게인 증폭 방지.
- **인접 밴드 평활도 ($\ell_s$)**: $\|\Delta\theta_{\text{eq}}\|_2^2 = \sum_{j=0}^{15} (\theta_{j+1} - \theta_j)^2$ $\rightarrow$ 이웃한 필터 간의 급격한 꺾임을 막아 매끄러운 자연스러운 톤 유지.

## 12. 다이내믹스(Dynamics) 최적화: Crest Factor 손실

컴프레서 임계값(Threshold $T$)을 조율하여 내 보컬의 다이내믹 레인지를 레퍼런스와 일치시키는 최적화 기준:

### 1) 크레스트 팩터 (Crest Factor, CF)의 정의

신호의 **최대 피크(Peak)**와 **평균 에너지(RMS)** 사이의 음량 차이(비율):

$$\mathrm{CF}(y) = \mathrm{True\ Peak}_{\mathrm{dB}}(y) - \mathrm{RMS}_{\mathrm{dB}}(y)$$

- **음향학적 의미**: 소리가 얼마나 순간적으로 튀는지(Spike), 아니면 고르게 압축되어 있는지(Dense)를 나타내는 다이내믹 레인지 척도.
  - **CF가 큰 소리**: 숨소리부터 샤우팅까지 편차가 큰 날것의 원본 보컬.
  - **CF가 작은 소리**: 컴프레서로 다이내믹스가 정돈되어 반주 위에 안정적으로 얹히는 상용 보컬.

### 2) 다이내믹스 최적화 손실 함수 ($\mathcal{L}_{\mathrm{dyn}}$)

컴프레서가 신호를 누를수록 CF 수치는 왜곡 없이 **단조 감소(Monotonicity)**하여 역전파 최적화에 완벽하게 부합:

$$\mathcal{L}_{\mathrm{dyn}} = \left|\mathrm{CF}(y_{\mathrm{comp}}) - \mathrm{CF}(r)\right|$$

- **레벨 무관 특성 (Level-invariance)**: 컴프레서 내부의 오토 메이크업 게인은 상수 dB 오프셋이므로 Crest Factor($\mathrm{Peak} - \mathrm{RMS}$)에는 영향을 주지 않음 $\rightarrow$ 순수한 다이내믹스 파형의 조밀도만 독립적으로 정확히 최적화.
- **효과**: 내 보컬의 다이내믹스($\mathrm{CF}$)를 레퍼런스 보컬과 정밀하게 일치시켜, **엔지니어가 수동으로 맞추듯 자연스럽고 일정한 음압**을 자동 실현.

## 13. 통합 목적 함수 & 상호 간섭 차단 (Selective Gradient)

음색과 다이내믹스를 동시에 조율할 때 두 플러그인이 서로 충돌하지 않도록 보장하는 핵심 공학 설계:

### 1) 전체 통합 목적 함수 (Total Objective)

$$\mathcal{L}_{\text{total}} = \underbrace{\mathcal{L}_{\text{mel}} + \lambda_2 \|\theta_{\text{eq}}\|_2^2 + \lambda_s \|\Delta\theta_{\text{eq}}\|_2^2}_{\text{EQ 최적화 (톤 밸런스)}} + \underbrace{\mathcal{L}_{\text{dyn}}}_{\text{Compressor 최적화 (다이내믹스)}}$$

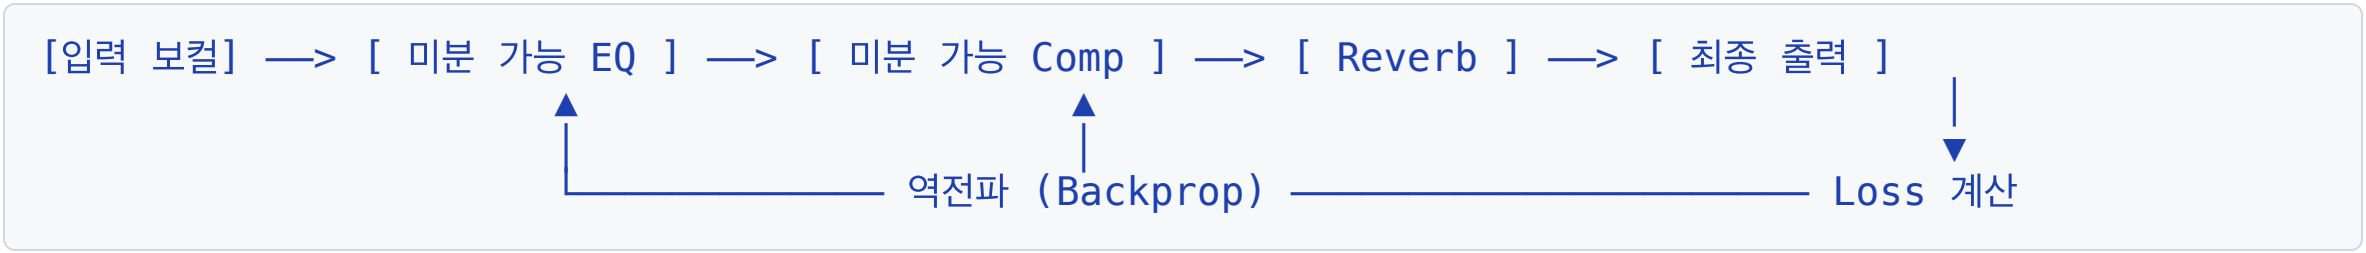
### 2) 핵심 제어 전략: 경사 분리 (`selective gradient`)

- **상호 간섭 문제**: 컴프레서가 신호를 누르면 스펙트럼 크기도 변하므로, 컴프레서 동작이 EQ 학습을 흔들고 EQ 부스트가 컴프레서 동작점을 틀어버리는 **파라미터 진동(Oscillation) 문제** 발생.
- **해결책**:

$$\frac{\partial \mathcal{L}_{\text{mel}}}{\partial \theta_{\text{comp}}} \leftarrow 0, \qquad \frac{\partial \mathcal{L}_{\text{dyn}}}{\partial \theta_{\text{eq}}} \leftarrow 0$$

  - **톤 손실($\mathcal{L}_{\text{mel}}$)은 오직 EQ 파라미터($\theta_{\text{eq}}$)로만 역전파.**
  - **다이내믹스 손실($\mathcal{L}_{\text{dyn}}$)은 오직 컴프레서 Threshold로만 역전파.**
- **효과**: 두 모듈이 서로의 영역을 침범하지 않고 **독립적이며 완벽한 단조 수렴(Monotonic Convergence)**을 달성.

## 14. End-to-End 경사하강법 워크플로우




- **손실 측정 지점 (`post_reverb`)**:
  - EQ, 컴프레서뿐만 아니라 공간 잔향(Reverb)까지 모두 반영된 **최종 출력 음원에서 Loss를 계산**하여, 실제 청취 환경 기준의 완벽한 밸런스를 유도.
- **최적화 1회 반복 사이클 (Iteration Cycle)**:
  - 초기 상태: $\theta_{\text{eq}} = 0$ (Flat EQ), Threshold = $-30\ \text{dB}$, Ratio = $10:1$
  - **1) 순전파 (Forward)**: EQ $\rightarrow$ Comp $\rightarrow$ Reverb를 거쳐 최종 스테레오 출력 생성
  - **2) 손실 계산 (Loss)**: 톤 오차($\mathcal{L}_{\text{mel}}$) + 다이내믹스 오차($\mathcal{L}_{\text{dyn}}$) + 정규화 손실 합산
  - **3) 역전파 (Backward)**: 그래디언트 계산 (Selective Gradient로 상호 간섭 차단)
  - **4) 파라미터 갱신 (Update)**: Adam Optimizer로 파라미터 업데이트 ($\text{lr}_{\text{eq}} = \text{lr}_{\text{comp}} = 0.05$, 전 모듈 동일)
- **안정적인 수렴 (50회 반복)**:
  - 수 시간~수 일이 소요되는 거대 딥러닝 모델 학습과 달리, **단 50회의 가벼운 반복 최적화(50 Iterations)**로 손실이 최적점으로 빠르게 수렴.
  - 곡 전체 처리 기준 **약 1~3분 내외 소요** (일반 CPU 환경 기준).

# 목차 (Table of Contents)


1 믹스의 정의 & 시스템 개요

2 핵심 도구 3종의 수학적 모델링 & 플러그인 설계

3 최적화 메커니즘 (Optimization Mechanism)

**4 풀믹스 합산 (Summing with Instrumental)**

5 마스터링 체인 (Mastering Chain)

6 결론 (Conclusion)

## 15. 풀믹스 합산: 인간 청각 인지 라우드니스(LUFS) 매칭

보컬과 반주를 합칠 때 곡 전체 평균을 쓰면, 반주의 조용한 인트로/아웃트로 때문에 후렴구에서 보컬 밸런스가 완전히 무너짐:

### 1) 인간 청각 인지 라우드니스: LUFS (ITU-R BS.1770-4)

단순 피크(Peak)나 RMS 대신 인간의 귀가 민감하게 반응하는 고역/저역을 보정한 국제 표준 라우드니스:

- K-Weighting 필터: 머리 형상 효과($+4\ \mathrm{dB}$) 및 저역 둔감도 보정.
- 2단 게이팅: 무음($-70\ \mathrm{LUFS}$) 및 조용한 구간($-10\ \mathrm{LU}$)을 통계에서 제외하여 핵심 소리 구간만 측정.

$$\mathrm{LUFS} = -0.691 + 10\log_{10}\left(\frac{\sum_j g_j z_j}{\sum_j g_j}\right)$$

### 2) 3초 슬라이딩 윈도우 최대 LUFS 정렬 & 헤드룸 보호

곡에서 가장 에너지가 폭발하는 하이라이트(후렴구) 구간의 음압을 정확히 타깃:

- 가장 큰 3초 구간 탐색: $\mathrm{LUFS}_{\mathrm{loudest}}(x) = \max_k \mathrm{LUFS}\big(x[kf_s : kf_s + 3f_s]\big)$
- 보컬 목표 레벨 정렬: $\Delta G_{\mathrm{dB}} = \mathrm{LUFS}_{\mathrm{loudest}}(\mathrm{Inst}) - \mathrm{LUFS}_{\mathrm{loudest}}(\mathrm{Vocal}) \quad \rightarrow \quad v_{\mathrm{scaled}} = v \cdot 10^{\Delta G_{\mathrm{dB}}/20}$
- 클리핑 방지: 헤드룸 $-1.0\ \mathrm{dBFS}$ 초과분만 $\tanh$로 부드럽게 완충 ($y_{\mathrm{mix}} = \mathrm{SoftLimit}(v_{\mathrm{scaled}} + \mathrm{Inst})$)

# 목차 (Table of Contents)


1 믹스의 정의 & 시스템 개요

2 핵심 도구 3종의 수학적 모델링 & 플러그인 설계

3 최적화 메커니즘 (Optimization Mechanism)

4 풀믹스 합산 (Summing with Instrumental)

**5 마스터링 체인 (Mastering Chain)**

6 결론 (Conclusion)

## 16. 마스터링(Mastering)이란 무엇인가?

### 1) 마스터링의 정의와 목적

- **정의**: 개별 트랙들을 합친 믹스다운(Mixdown) 트랙을 모든 상용 스트리밍 플랫폼(Spotify, Apple Music, YouTube) 및 다양한 스피커 환경에서 **최고의 음질과 균일한 음압**으로 재생되도록 가공하는 최종 상용화 단계.
- **핵심 작업 3요소**:
  i. **전체적 톤 밸런스 정돈 (Mastering EQ)**: 특정 악기가 튀지 않도록 전체 주파수 균형 완성.
  ii. **상용 음압(Loudness) 극대화**: 상용 음원들과 경쟁 가능한 음압 확보.
  iii. **디지털 피크 제어 (Brickwall Peak Limiting)**: $0\ \mathrm{dBFS}$를 넘는 클리핑 차단.

# 17. 마스터링 1단계: Full-band Mastering EQ (`master_track`)

풀믹스의 멜 스펙트럼 포락선을 레퍼런스 곡에 매칭 (`modules.py:818–845` 구현 기반):

## 1) 믹싱 EQ vs 마스터링 EQ 파라미터 비교

| 파라미터 | 보컬 믹싱 EQ (`DifferentiableEQ`) | 마스터링 EQ (`master_track`) | 코드 위치 / 설정 근거 |
|---|---|---|---|
| 처리 대상 | 단일 보컬 트랙 | 풀믹스 트랙 | `modules.py:812` |
| 주파수 대역 | $200\ \text{Hz} \sim 10\ \text{kHz}$ | $20\ \text{Hz} \sim 20\ \text{kHz}$ | `modules.py:117–120` 주석 |
| 밴드 수 (`num_bands`) | 17-Band | 15-Band | `modules.py:793` |
| 게인 스케일 계수 (`gain_scale_db`) | $15.0\ \text{dB}$ (기울기 스케일 $d/d\theta$) | $8.0\ \text{dB}$ (기울기 스케일 $d/d\theta$) | `modules.py:163, 794` |
| 클램프 (`hard_clamp`) | `False` (선형 개방) | `False` (선형 개방) | `modules.py:819` 주석 |
| L2 페널티 (`eq_l2`) | $0.1$ | $1.0$ | `modules.py:820` 주석 |
| 스무딩 페널티 (`eq_smooth`) | $0.1$ | $1.0$ | `modules.py:820` 주석 |
| 학습률 (`lr_eq`) | `0.05` (실제 변위 $\approx 0.75\ \text{dB/step}$) | `0.05` (실제 변위 $\approx 0.40\ \text{dB/step}$) | `pipeline.py:831`, `modules.py:798, 841` |
| 반복 횟수 (`eq_iters`) | 50 (E2E 전체 파이프라인) | 300 (스펙트럼 매칭 루프) | `modules.py:794` |

# 18. 마스터링 2단계: 보컬 믹싱 컴프 vs 마스터링 리미터 비교

풀믹스 다이내믹 제어 및 상용 음압(LUFS) 매칭 (`modules.py:882-960` 구현 기반):

## 1) 믹싱 컴프 vs 마스터링 리미터 파라미터 비교

| 파라미터 | 보컬 믹싱 컴프 (`DifferentiableCompressor`) | 마스터링 리미터 (`DifferentiableLimiter`) | 코드 위치 / 설정 근거 |
|---|---|---|---|
| 처리 대상 | 단일 보컬 트랙 (모노/스테레오) | 풀믹스 2트랙 (`mix = vocal + inst`, 스테레오 링크) | `pipeline.py:624`, `modules.py:715` |
| 핵심 목적 | 보컬 다이내믹 레인지 정돈 & Crest Factor 매칭 | 상용 음압(LUFS) 확보 & $0\ \mathrm{dBFS}$ 클리핑 방지 | `losses.py:328`, `modules.py:802` |
| 제어 파라미터 | Threshold ($T_{\mathrm{comp}}$) 하강 | 입력 드라이브 게인 ($G_{\mathrm{in}}$) 상승 | `pipeline.py:702`, `modules.py:906` |
| 천장/기준점 | 가변 Threshold ($T \in [-30, 0]\ \mathrm{dB}$) | Ceiling 고정 ($-0.3\ \mathrm{dBFS}$) | `modules.py:794, 887` |
| 압축 비율 (`ratio`) | $10.0 : 1$ (보컬 다이내믹 압축) | $50.0 : 1$ (브릭월 피크 리미팅) | `pipeline.py:149`, `modules.py:796` |
| 어택 타임 (`attack_ms`) | $0.5\ \mathrm{ms}$ (보컬 트랜지언트 엔벨로프 추종) | $0.1\ \mathrm{ms}$ (순간적 인터샘플 피크 즉각 차단) | `pipeline.py:602`, `modules.py:796` |
| 릴리즈 타임 (`release_ms`) | $120.0\ \mathrm{ms}$ (자연스러운 보컬 서스테인 복원) | $80.0\ \mathrm{ms}$ (믹스 펌핑 방지 및 빠른 복원) | `pipeline.py:603`, `modules.py:796` |

| 파라미터 | 보컬 믹싱 컴프 (`DifferentiableCompressor`) | 마스터링 리미터 (`DifferentiableLimiter`) | 코드 위치 / 설정 근거 |
|---|---|---|---|
| 소프트 니 (`knee_db`) | $2.0\ \mathrm{dB}$ | $1.0\ \mathrm{dB}$ (천장 경계 정밀 완충) | `modules.py:276, 797` |
| 최적화 손실 함수 | $\mathcal{L}_{\mathrm{dyn}} = \lvert \mathrm{CF}_{\mathrm{src}} - \mathrm{CF}_{\mathrm{ref}} \rvert + \lambda_{\mathrm{th}} \mathrm{ReLU}(T - T_{\max})^2$ | $\mathcal{L} = \mathrm{ReLU}(G_{\mathrm{target}} - G_{\mathrm{in}})^2 + 25.0 \cdot \mathrm{ReLU}(\max(\mathrm{GR}) - 3.0)^2$ | `losses.py:328`, `modules.py:928–932` |
| 게인 보상 / 안전 장치 | 활성 구간 평균 GR 계산 후 deterministic offset | 3.0 dB GR 상한선 페널티 + 3.5 dB 하드 캡 가드 | `pipeline.py:734`, `modules.py:943–953` |
| 학습률 / 스텝 | `lr_comp = 0.05`, 50 스텝 E2E (모듈별 분리 그래디언트) | `lr = 0.05`, 800 스텝 단일 학습률 Adam | `pipeline.py:832`, `modules.py:749–750, 921` |

### 2) 왜 Threshold가 아닌 입력 드라이브(볼륨)를 올리는가?

- **천장(Ceiling) $-0.3\ \mathrm{dBFS}$ 고정의 원칙 (`modules.py:794`)**:
  - DAC(디지털-아날로그 변환기) 재생 시 인터샘플 피크(Inter-sample Peak) 클리핑을 막기 위해 Ceiling은 $-0.3\ \mathrm{dBFS}$에 단단히 고정되어야 함.
- **Threshold 하강 vs 입력 드라이브 상승의 메커니즘 차이**:
  - **보컬 믹싱**: 트랙 자체의 동적 편차를 줄이기 위해 Threshold를 낮추고, 압축으로 깎인 레벨은 활성 구간 평균 게인 리덕션($\overline{\mathrm{GR}}_{\mathrm{active}}$)만큼 들어 올려 보상함.
  - **마스터링**: 천장($-0.3\ \mathrm{dBFS}$)을 고정한 채 **`drive_gain`** **($G_{\mathrm{in}}$)으로 신호를 밀어 올려 상용 음압(LUFS)을 채우고**, 천장을 넘어서는 극단적 피크만 $50:1$ 비율로 투명하게 리미팅함 (`modules.py:882–960`).

# 목차 (Table of Contents)


1 믹스의 정의 & 시스템 개요

2 핵심 도구 3종의 수학적 모델링 & 플러그인 설계

3 최적화 메커니즘 (Optimization Mechanism)

4 풀믹스 합산 (Summing with Instrumental)

5 마스터링 체인 (Mastering Chain)

**6 결론 (Conclusion)**

## 19. 결론 (Conclusion)

1. **패러다임 전환**:
   - 정답 데이터셋이 없는 실제 음악 제작 환경에서, **단 하나의 레퍼런스 곡만을 이용해 최적의 믹싱·마스터링 값을 도출하는 비지도 최적화 파이프라인**을 완성함.
2. **수학적 엄밀성과 물리 음향학의 결합**:
   - 전 구간 미분 가능한 형태로 설계하여 그래디언트 소실 없이 End-to-End 경사하강법을 구현함.
   - 음원 분리 ai의 한계점인 마스킹(200Hz) 및 코덱 절벽(10kHz)을 공학적으로 격리하여 ai의 한계 개선.

# Q & A

감사합니다.
질문이 있으시면 자유롭게 말씀해 주시기 바랍니다.